

Bakalářská práce



České
vysoké
učení technické
v Praze

F3

Fakulta elektrotechnická
Katedra kybernetiky

Následování člověka mobilním robotem

Mykhaylo Zelenskyy

Školitel: Ing. Jan Chudoba
Květen 2017

Poděkování

Prohlášení

I declare that this work is all my own work and I have cited all sources I have used in the bibliography.

Prague, May 16, 2017

Prohlašuji, že jsem předloženou práci vypracoval samostatně, a že jsem uvedl veškerou použitou literaturu.

V Praze, 16. května 2017

Abstrakt

V práci je probírána problematika následování člověka mobilním robotem. Pro detekci vizuální značky, dle které je člověk sledován, jsou použity korelační algoritmus a detektor ArUco markerů. Pro řízení robotu je použit diskretní PID regulátor. Také je použit algoritmus Vector Field Histogram pro vyhýbání se překážkám. Software byl vyzkoušen v simulátoru V-Rep a také na reálném robotu.

Klíčová slova: robotika, počítačové vidění, řízení robotu, korelace, ArUco, PID, VFH, V-Rep

Školitel: Ing. Jan Chudoba

Abstract

This thesis is focused on the problem of following of human by mobile robot. The correlation algorithm and ArUco marker detector are used for detection of visual mark used for defining the followed person. Discrete PID controller is used for robot control. Also Vector Field Histogram algorithm is used for obstacle avoidance. Software was tested in V-Rep simulator and with real robot.

Keywords: robotics, computer vision, robot control, correlation, ArUco, PID, VFH, V-Rep

Title translation: Following of Human by Mobile Robot

Obsah

1 Úvod	1
1.1 Cíl práce	1
1.2 Motivace	2
2 Návrh systému	3
2.1 Volba vizuální značky	3
2.2 Volba souřadnicového systému...	4
2.3 Implementační záležitosti	4
3 Detekce	7
3.1 Zpracování obrazu z kamery	7
3.2 Rozpoznávání vzoru	7
3.2.1 Korelační algoritmus	8
3.2.2 ArUco marker detektor	10
3.3 Měření polohy cíle	11
3.4 Kalmanův filtr	11
4 Řízení robotu	15
4.1 Vyhýbání se překážkám	15
4.1.1 Algoritmus Bug	16
4.1.2 Vector Field Histogram (VFH)	16
4.2 PID regulátor	19
5 Simulace	21
5.1 Porovnání algoritmů detekce ...	21
5.2 Porovnání naměřených a reálných hodnot	22
5.3 Měření polohy robotu	24
5.4 Trajektorie robotu při jízdě s překážkami	25
6 Závěr	27
A Literatura	29
B Obsah CD	31

Obrázky

1.1 Robot následující člověka	2
2.1 Příklad vizuální značky	4
2.2 Použitý souřadnicový systém	5
3.1 Příklad použití adaptivního prahování [1]	8
3.2 Hierarchie (topologie) obrazu [2]	8
3.3 Příklad korelace mezi markery vůči referenčnímu	9
3.4 Aproximace křivky pomocí Ramerova Douglasova Peuckerova algoritmu	10
3.5 Buňky ArUco markeru	10
3.6 Vyhodnocení obrázku pomocí detektoru ArUco	11
3.7 Měření veličiny d a ϕ	12
3.8 Shrnutí algoritmu Kalmanova filtru	13
3.9 Odvození hodnot d a ϕ ze známé polohy cíle	14
4.1 Lokální mapa prostředí o poloměru $r_{map} = 10$	16
4.2 Polární histogram s vyobrazenými prahy τ_{low} (zeleně) a τ_{high} (fialově)	18
4.3 PID regulace	19
5.1 Roboty vytvořené v simulátoru V-Rep	22
5.2 Příklad značky pro korelační algoritmus	22
5.3 Poloha sledovaného objektu během simulace	23
5.4 Vzdálenost mezi robotem a sledovaným objektem (d)	23
5.5 Odchylka sledovaného objektu od středu kamery ϕ	24
5.6 Poloha robotu během simulace	25
5.7 Simulace s člověkem a překážkami	25
5.8 Trajektorie robotu a člověka	26

Tabulky

4.1 Souhrn základních algoritmů pro vyhýbání se překážkám [3, s. 287–290]	15
4.2 Vliv zvětšení koeficientů PID regulátoru na kvalitu regulace	20
4.3 Nastavení koeficientů PID regulátoru pomocí Zieglerovy Nicholsovy metody	20
5.1 Porovnání korelačního algoritmu a ArUco detektoru	21

Kapitola 1

Úvod

Pomocný robot se může mnohým z nás zdát jako futuristický sen. Takový robot by místo nás nosil věci, pomáhal při nákupech, asistoval v nemocnicích či ošetřoval raněné ve válkách. Měl by tolik výhod, že by v budoucnu bylo trendem tohoto pomocníka vlastnit.

Bylo provedeno mnoho různých výzkumů ohledně návrhu robotů, které by dokázaly sledovat člověka. S tímto problémem jsou spojené dvě důležité otázky. Jaké senzory použít pro lokalizaci člověka? Jak řešit řízení a navigaci robotu tak, aby udržoval určitou vzdálenost a vyhýbal se případným překážkám?

Nejdříve je třeba definovat, co vlastně je robotem následující člověka. Jedná se o mobilního robota, který sleduje určitou osobu a zároveň objíždí překážky a chová se k ostatním lidem jako k překážkám, tj. nezmění cíl sledování během jízdy.

Takový robot typicky může být vybaven mnoha různými senzory, např. laserovým, zvukovým nebo IR dálkoměrem, aby mohl měřit vzdálenost od překážek, kamerou pro detekci sledovaného objektu, bezdrátovým přenášecem signálu, GPS apod. Tyto senzory by měly fungovat současně, aby robot dokázal všechno, co se od něj očekává.

1.1 Cíl práce

Cílem této práce je navrhnout systém pro řízení robotu, tak aby dokázal splnit úkoly definované v úvodu.

Při návrhu tohoto systému je třeba uvědomit si několik věcí:

1. Pro detekování člověka by měl být použit takový algoritmus, který dokáže fungovat v prostředí, kde kromě sledovaného člověka jsou i další lidi.
2. Cíl se nesmí pohybovat průměrnou rychlostí větší, než je maximální rychlost robotu. Může se stát, že robot už nikdy nedokáže najít sledovaného člověka, dokud se dotyčný nevrátí na dostatečně blízko k robotu.
3. V případě použití dálkoměru pro měření vzdálenosti mezi objekty je důležité, aby systém nedetekoval sledovaný cíl jako překážku.



Obrázek 1.1: Robot následující člověka

■ 1.2 Motivace

Jak již bylo řečeno, robot s podobnou funkcionalitou by byl velice užitečný jako pomocník v různých oborech lidské činnosti. V medicínských zařízeních a domovech pro seniory by se takový robot mohl starat o pacienty (viz obr. 1.1), také by našel své uplatnění v armádě, kde by pomáhal vojákům s převozem nákladů. Vylepšená varianta robota by mohla posloužit jako tělesná stráž.

Kapitola 2

Návrh systému

Problematiku detekci člověka lze řešit pomocí nevizuálních nebo vizuálních metod. Zatímco co první používají různé senzory, jako např. dálkoměr, druhé spoléhají na kameru. Každá z těchto metod má své výhody a nevýhody, proto před samotným návrhem programu pro následování člověka mobilním robotem je třeba zhodnotit používané přístupy.

■ Nevizuální metody


■ Vizuální metody

Existuje několik výzkumných projektů, které se zabývají problematikou pomocných robotů, které by následovaly člověka za použití vizuálních metod. Většina těchto projektů zakládá na detekci pohybujícího se objektu, které je následně sledován. V některých pracích jsou použity neuronové sítě pro detekci obličeje spolu s background subtraction pro nalezení pohybu v obraze [4], např. pohybující se nohou člověka. Avšak použití tohoto algoritmu vede k tomu, že sledovaný člověk musí být otočen k robotu obličejem, a presence několika lidí v místnosti přivede k tomu, že robot nedokáže určit, koho musí následovat. V případě, že neuronová síť bude naučena pouze na konkrétního člověka, což by tento problém mohlo řešit, znovupoužitelnost algoritmu klesá. Jelikož síť by byla naučena pouze pro jednu osobu, bylo by ji třeba přeučovat pro každé nové použití algoritmu.

Dalším možným řešením této problematiky je použití barevného markeru [5], což znamená, že robot hledá určitou shodu barev, kterou pak sleduje. V tomto případě člověk může být otočen k robotu zády, a algoritmus může být použit i v plných lidí prostorech. Avšak detekce barevného vzoru nemusí být robustní kvůli změně osvětlení nebo špatné volbě barev, které nebudou dostatečně kontrastní v porovnání s oblečením sledovaného člověka.

■ 2.1 Volba vizuální značky

Po vyhodnocení možných přístupů k řešení problému následování člověka mobilním robotem bylo rozhodnuto použít vizuální metodu, která by zakládala na hledání specifické vizuální značky umístěné na člověku. Cíl pro sledování



Obrázek 2.1: Příklad vizuální značky

musí být unikátní, a algoritmus detekce musí být robustní, aby nedocházelo k tomu, že robot nebude vědět, koho má sledovat. Bude známo, jaký typ značky robot musí hledat, proto se snižuje šance, že si splete cíl s jiným člověkem nebo překážkou.

Mobilní robot bude následovat člověka, který má na sobě umístěnou předem známou vizuální značku. Pro navigaci robotu se v praxi běžně používají markery pro rozšířenou realitu [6][7][8]. Jejich detekce je většinou jednoduchá a můžou v sobě uchovávat užitečnou informaci, např. identifikační číslo, podle kterého robot pozná, koho sleduje. Jednu z možných vizuálních značek, které jsou v této práci použity, lze vidět na obrázku 2.1.

2.2 Volba souřadnicového systému


Pro řízení robotu je třeba zvolit souřadnicový systém, ve kterém se bude pohybovat.

Počátek zvolené souřadnicové soustavy umístěn do počáteční pozice robotu a osa X je ve stejném směru, jako počáteční směr jízdy robotu. Kladný směr jízdy robotu je v kladném směru osy Y , jak je vyobrazeno na 2.2, a je v rozmezí $(-\pi; \pi)$. Poloha cíle (viz sekci 3.3) je poté vztažena k poloze robotu a je počítána v čárkované soustavě, jejíž počátek je umístěn do aktuální pozice robotu, a je vůči původní otočená o h , kde h je směr jízdy robotu.

2.3 Implementační záležitosti

Protože se očekává, že běh software bude v reálném čase, musí být rychlý a stabilní. Z těchto důvodů bylo rozhodnuto, že bude použit jazyk C++.

Také v práci je použita knihovna OpenCV[9], která nabízí obrovské možnosti pro zpracování obrazu. Tato knihovna obsahuje přes 2500 optimalizovaných algoritmů pro počítačové vidění a strojové učení. Některé z nich budou použity



Obrázek 2.2: Použitý souřadnicový systém

pro detekci vizuální značky ve výstupu z kamery. Navíc v této knihovně je implementován algoritmus pro detekci ArUco markeru [6], který je podrobněji popsán v sekci 3.2.2.

Kapitola 3

Detekce

3.1 Zpracování obrazu z kamery

Než bude možné použít rozpoznávací algoritmy, výstup z kamery musí být náležitě zpracován, aby odpovídal formátu, se kterým algoritmy pracují.


Načtený snímek je převeden do černobílé podoby, je tedy použito prahování. Jelikož se předpokládá, že se robot může pohybovat v prostředí s nerovnoměrným osvětlením, pro binarizaci obrazu je vhodné použít adaptivní prahování [1] (viz obr. 3.1). Tato metoda počítá práh pro malé části obrazu místo globálního nastavení prahu pro celý snímek.

Dále je třeba najít kontury. Cannyho algoritmus pro nalezení kontur je implementován v knihovně OpenCV. Tato funkce navíc zajišťuje zachování hierarchie kontur[2], tedy topologii obrázku, jak je vidět na 3.2. Tato informace je užitečná pro následné rozpoznávání, protože pak kontury na nejnižší nebo nejvyšší úrovni hierarchie můžou být ignorovány, pokud se předpokládá, že vizuální značka bude umístěna v ochranné zóně a bude obsahovat další pod-vzory.

3.2 Rozpoznávání vzoru


Pro rozpoznávání vizuální značky je vhodné použít algoritmus, který zakládá na hledání známého vzoru v obraze. Nejběžnější metodou, která se pro této účely používá, je Template Matching [10]. Podstatou této metody je to, že se pro různé velikosti vstupního obrazu počítá jeho korelace se známým vzorem. Kvůli tomu, že vzor může mít v obraze jinou velikost, než je reálná, vytváří se tzv. pyramida obrazů [11]. Tato pyramida se skládá ze vstupních obrázků různé velikosti a orientace. Každý obraz v této pyramidě je rozdělen na oblasti o stejné velikosti, jako je reálná velikost vzoru. Pro každou z těchto oblastí se výpočte korelace se vzorem. Následně je zvolena oblast, kde je korelační koeficient největší.

Kvůli tomu, že korelace musí být spočtena pro velký počet vstupních obrazů o různé velikosti, Template Matching může být pomalý. Jelikož se předpokládá použití čtvercové vizuální značky, je praktičtější nejdříve najít oblast zájmu (Region of Interest, ROI), pro níž se spočte korelace se známým vzorem.



(a) : Před prahováním

(b) : Po prahování


Obrázek 3.1: Příklad použití adaptivního prahování [1]**Obrázek 3.2:** Hierarchie (topologie) obrazu [2]

Proto pro detekci vizuální značky byl navržen korelační algoritmus, který je popsán v následujícím textu. Pro porovnání funkčnosti tohoto algoritmu byl použit ArUco marker detektor [12], který je k dispozici v knihovně OpenCV.

■ 3.2.1 Korelační algoritmus

Tento algoritmus využívá principu korelace mezi dvěma veličinami, tedy mezi známým vzorem a nalezenou ROI. Korelace uvádí, jak jsou na sobě tyto veličiny závislé, a může nabývat hodnot od -1 do +1. Hodnota korelačního koeficientu blízká -1 značí nepřímou závislost veličin, koeficient blízký +1 naopak značí přímou závislost, což je zobrazeno na 3.3.

Hledaná ROI je v zjednodušeném případě konvexní čtyřúhelník, proto stačí s použitím informace o topologii obrazu spočítat polygony nalezených kontur a vybrat pouze ty, co obsahují čtyři strany a nejsou konkávní. Pro aproximaci křivky se používá Ramerův Douglasův Peuckerův algoritmus [13] (viz obr. 3.4), který je již implementován v OpenCV.



Obrázek 3.3: Příklad korelace mezi markery vůči referenčnímu

Následně je spočítána transformační matice mezi nalezeným polygonem a známým vzorem. Pomocí této matice se polygon převede do takové podoby, aby byl porovnatelný se vzorem.

Dále dojde k vyhodnocení korelace nalezené ROI a vzoru. Pokud je vypočtený korelační koeficient větší, než zadaný práh, ROI se vyhodnotí jako správně označena a algoritmus vrátí souřadnice jejích rohů pro následné zpracování.


Korelaci mezi dvěma obrázky I_1 a I_2 s N pixely je vypočtena následujícím způsobem:

$$\mu_{1,2} = \frac{\sum_{i,j} I_{i,j}}{N}, \quad (3.1)$$


$$\sigma_{1,2} = \sqrt{\left(\frac{\sum_{i,j} (I_{i,j} - \mu_{1,2})^2}{N} \right)}, \quad (3.2)$$

$$\text{covar}(I_1, I_2) = \frac{(I_1 - \mu_1) \cdot (I_2 - \mu_2)}{N}, \quad (3.3)$$

$$\text{cor}(I_1, I_2) = \frac{\text{covar}(I_1, I_2)}{\sigma_1 \sigma_2}. \quad (3.4)$$



Obrázek 3.4: Aproximace křivky pomocí Ramerova Douglasova Peuckerova algoritmu




Obrázek 3.5: Buňky ArUco markeru

■ 3.2.2 ArUco marker detektor

Tento algoritmus je implementován v OpenCV knihovně a umožňuje rozpoznávání ArUco markerů nebo podobných vizuálních značek. Podobně jako výše uvedený korelační algoritmus, hledá konvexní čtyřúhelník. Rozdíl pak spočívá v odlišném zpracování nalezené ROI, kde se místo korelace využívá binární mapa kandidáta.

ROI je rozdělena na mřížku s počtem buněk rovným počtu bitů hledaného vzoru (viz obr. 3.5). Následně se spočítá, kolik bílých a černých pixelů obsahuje každá buňka, na základě čehož se vyhodnotí, jestli buňka je černá nebo bílá (viz obr. 3.6). Pokud detektor ve svém slovníku obsahuje vzor se stejnou binární maskou, vrátí souřadnice rohů nalezené ROI.



Obrázek 3.6: Vyhodnocení obrázku pomocí detektoru ArUco

3.3 Měření polohy cíle

Algoritmy popsané výše naleznou polohu vizuální značky v obraze, z čehož lze spočítat její umístění vůči kameře, je-li známa velikost této značky. Pro výpočty lze použít model ideální (dírkové) kamery [14], kde vzdálenost mezi kamerou a značkou je vyjádřena jako

$$d = \frac{fX}{x}, \quad (3.5)$$

kde x značí nejkratší vzdálenost mezi dvěma rohy nalezené značky, f je ohnisková vzdálenost a X je známá délka hrany značky.

Pro nalezení posunutí značky vůči kameře při odklonění od její osy musí být znám zorný úhel kamery. Ten lze spočítat dle vztahu

$$\alpha = 2 \arctan \left(\frac{w}{2f} \right), \quad (3.6)$$

kde w je šířka výstupního obrazu z kamery.

Potom úhel, který pokrývá jeden pixel snímku, je vyjádřen vztahem

$$APP = \frac{\alpha}{w}. \quad (3.7)$$


Následně posunutí objektu vůči středu kamery je

$$\phi = (x_c - x_t)APP, \quad (3.8)$$

kde x_c je pixel vyjadřující střed kamery v horizontálním směru, x_t je pixel vyjadřující střed nalezené značky v horizontálním směru.

3.4 Kalmanův filtr

Při sledování člověka může nastat situace, že vizuální značka nebude detekovatelná. Potom není možnost spočítat polohu značky vůči robotu, a tak robot

Obrázek 3.7: Měřené veličiny d a ϕ

buď zastaví, nebo bude pokračovat pohyb dle posledního měření. Toto může přivést k tomu, že se člověk bude muset vrátit k robotu, aby ten ho znovu začal sledovat. Aby tato situace nenastala, je třeba predikovat polohu cíle z předchozích měření. Pro tyto účely je v práci použit Kalmanův filtr [15].

Model lze popsat pomocí následujícího stavového vektoru:

$$\mathbf{x} = \begin{bmatrix} x & y & v_x & v_y \end{bmatrix}^T, \quad (3.9)$$

kde v_x , resp. v_y , značí rychlost ve směru osy X, resp. Y.

Stavový model je pak vyjádřen jako

$$\mathbf{x}_{t+1} = \mathbf{F}\mathbf{x}_t, \quad (3.10)$$

kde \mathbf{F} je matice přechodu stavů \mathbf{x} z času t do času $t + 1$ a platí, že

$$\mathbf{F} = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 \\ 0 & 0 & dt & 0 \\ 0 & 0 & 0 & dt \end{bmatrix}. \quad (3.11)$$

Pro sledování cíle lze Kalmanův filtr rozdělit do tří kroků:

1. Inicializace ($t = 0$). Během tohoto kroku je nastavena počáteční pozice cíle \mathbf{x}_0 a výchozí hodnota pro kovarianční matici \mathbf{P}_0 . Jelikož počáteční pozice cíle nemusí být známa, je vhodné zvolit \mathbf{x}_0 tak, aby v případě, že kamera nedetekuje značku po první iteraci, zůstal robot na místě.

2. Predikce ($t > 0$). V tomto kroku se provádí predikce polohy cíle v čase $t + 1$, tj. \mathbf{x}_{t+1} , dle 3.10. Také se počítá nová kovarianční matice dle následujícího vztahu

$$\mathbf{P}_{t+1} = \mathbf{F}\mathbf{P}_t\mathbf{F}^T + \mathbf{Q}_{t+1}, \quad (3.12)$$

kde \mathbf{Q} značí matici kovariancí šumů (výpočet viz [16]).

3. Filtrace ($t > 0$). Během tohoto kroku je poloha cíle upřesněna na základě provedeného měření. Nejdříve se spočte rozdíl mezi reálnou polohou a predikovanou v kroku 2.:

$$\mathbf{y}_t = \begin{bmatrix} x_{m_t} \\ y_{m_t} \end{bmatrix} - \mathbf{H}\mathbf{x}_t, \quad (3.13)$$

kde

$$\mathbf{H} = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix}. \quad (3.14)$$

Dále se vypočítá Kalmanovo zesílení, pro nějž platí:

$$\mathbf{K}_t = \mathbf{P}_t\mathbf{H}^T(\mathbf{H}\mathbf{P}_t\mathbf{H}^T + \mathbf{R})^{-1}, \quad (3.15)$$

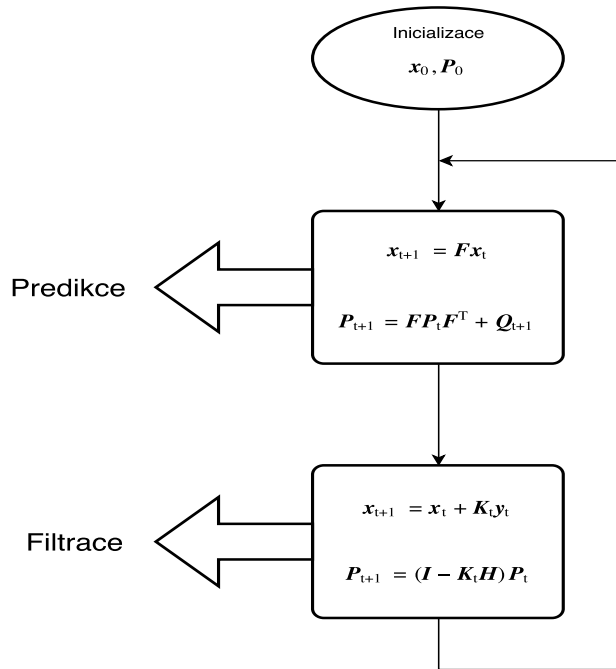
kde \mathbf{R} je matice kovariancí šumů (výpočet viz [16]).

Následně se provede zpřesnění polohy cíle a aktualizuje se kovarianční matice:


$$\mathbf{x}_{t+1} = \mathbf{x}_t + \mathbf{K}_t\mathbf{y}_t, \quad (3.16)$$

$$\mathbf{P}_{t+1} = (\mathbf{I} - \mathbf{K}_t\mathbf{H})\mathbf{P}_t. \quad (3.17)$$

Celý proces lze shrnout pomocí diagramu 3.8.



Obrázek 3.8: Shrnutí algoritmu Kalmanova filtru



Obrázek 3.9: Odvození hodnot d a ϕ ze známé polohy cíle

Z nalezených hodnot x a y lze jednoduše odvodit hodnoty d a ϕ , což je také vidět na 3.9. Jelikož se předpokládá, že poloha robotu je známa, lze spočítat x_t a y_t , což je poloha cíle vůči robotu, jako:

$$x_t = x - x_r, \quad (3.18)$$

$$y_t = y - y_r. \quad (3.19)$$

Dále jsou pak ϕ a d nalezeny dle vztahů:

$$\phi = h - \text{atan2}(y_t, x_t), \quad (3.20)$$

$$d = \sqrt{x_t^2 + y_t^2} \cos(\phi). \quad (3.21)$$

Kapitola 4

Řízení robotu

4.1 Vyhýbání se překážkám

Pro řízení autonomního robotu je důležité, aby se během sledování cíle dokázal vyhýbat překážkám. Algoritmů pro řízení robotu v prostředí s překážkami je několik [3], jejichž přehled je k nalezení v tabulce 4.1. V tabulce je uveden název metody, kinematika použitého robotu a prostředí, pohled na vytvářený model prostředí, mapa, která se pro algoritmus používá, a druhy senzorů, které je třeba pro algoritmus použít.

Omezením na výběr algoritmu pro vyhýbání se překážkám je to, že se robot bude pohybovat v prostředí, které není dopředu známo. Proto je výhodnější použít algoritmus, který pracuje s lokální mapou prostředí vytvořenou kolem robotu místo globální. Navíc při použití vztažné soustavy a diferenciálního výpočtu polohy a rychlosti robotu nelze přesně stanovit, kde se nachází on nebo překážky kolem něj. Proto je třeba použít algoritmus, který by pracoval pouze se základní kinematikou robotu a prostředí.

S uvážením těchto omezení, nejvhodnějšími algoritmy pro řešení zadaného problému jsou algoritmus Bug [3, s. 272–276] nebo Vector Field Histogram [3, s. 276–278][17].

Metoda	Kinematika	Pohled	Mapa	Senzor
Bug	Žádná	Lokální	Žádná Lokální graf tečen	Dotykový Dálkový
VFH	Záklaní	Lokální	Mřížový histogram	Dálkový
Bubble band	Přesná	Lokální Globální	Globální polygon	Různé
Curvature velocity	Přesná	Lokální	Mřížový histogram	Dálkový
Dynamic window	Přesná	Globální	Obstacle line field	Dálkový
Nearness diagram	Holonomní	Globální	Žádná	Dálkový
Gradient method	Přesná	Globální	Žádná	Dálkový

Tabulka 4.1: Souhrn základních algoritmů pro vyhýbání se překážkám
[3, s. 287–290]

4.1.1 Algoritmus Bug


Tento algoritmus je nejjednodušším algoritmem pro vyhýbání se překážkám. Podstatou algoritmu je to, že robot narazí na překážku a následuje její konturu. Existuje několik obdob toho algoritmu, které se liší v tom, jak je obvod překážky sledován robotem. Například algoritmus Bug1 prvně s použitím dotykového senzoru objede celou překážku, následně zvolí bod, který je nejbližší cíli, vrátí se tam a pokračuje směrem k cíli. Tento postup je dost neefektivní, ale zajišťuje, že robot vždy dosáhne cíle.

Možným vylepšením tohoto algoritmu je Tangent Bug, který používá dálkoměr pro měření vzdálenosti k překážkám a vytváří model lokálního prostředí, který je reprezentován jako graf.

Nevýhodou algoritmu Bug je to, že když nalezne jakoukoliv překážku, snaží se sledovat její konturu, nikoliv se jí přímo vyhnout. Proto při následování cíle se může stát, že kvůli sledování obrysu překážky dojde ke ztátě cíle ze zorného pole a již nebude možnost odhadnout jeho pozici. Proto v praxi je použit Vector Field Histogram, který je navržen tak, aby se robot snažil překážky objíždět dříve, než bude v nebezpečné zóně blízko k překážkám.

4.1.2 Vector Field Histogram (VFH)

Princip tohoto algoritmu spočívá v tom, že se na základě dat naměřených dálkoměrem vytvoří lokální mřížková mapa prostředí o poloměru r_{map} a se zvoleným rozlišením. Každá buňka této mapy tak obsahuje hodnotu obsazenosti odpovídající oblasti v reálném světě (viz obr. 4.1). Z této mapy se následně spočítá polární histogram, podle kterého se určí směr jízdy robotu.



Obrázek 4.1: Lokální mapa prostředí o poloměru $r_{map} = 10$

Celý proces tímto způsobem lze rozdělit na tři kroky: vytvoření primárního polárního histogramu, prahování primárního histogramu (vytvoření binární

reprezentace), a nakonec výběr kandidátů pro směr pohybu.

■ Primární polární histogram

Polární histogram je rozdělen na sektory tak, aby každý z nich odpovídal úhlu α , který je volen takovým způsobem, aby $\frac{360}{\alpha}$ bylo celé číslo. Tedy například pro $\alpha = 15^\circ$ histogram obsahuje 24 sektorů (viz obr. 4.2).

Pro každou buňku aktivního regionu, tedy lokální mapy vytvořené kolem robotu, se spočte směr, ve kterém se vůči středu nachází, a její význam. Směr je spočítán dle vztahu:

$$\beta_{i,j} = \text{atan2}(y_o - y_i, x_o - x_i), \quad (4.1)$$

kde x_o, y_o značí souřadnice střed mapy, x_i, y_i jsou souřadnice buňky.

Dále pak významnost buňky je:

$$m_{i,j} = c_{i,j}^2(a - bd_{i,j}^2), \quad (4.2)$$

kde $c_{i,j}$ je obsazenost buňky a $d_{i,j}$ vzdálenost buňky od pozice robotu.

Parametry a a b jsou voleny dle vztahu:

$$a - b \left(\frac{r_{map} - 1}{2} \right) = 1. \quad (4.3)$$

Aby robot nejel blízko k okrajům překážek, zavádí se kompenzace jeho velikosti pomocí poloměru robotu r_{rob} a minimální povolené vzdálenosti mezi robotem a překážkou d_{safety} :

$$\gamma_{i,j} = \arcsin \left(\frac{r_{rob} + d_{safety}}{d_{i,j}} \right)$$

. Histogram je potom spočten vztahem:

$$H_k^p = \sum_{i,j \in C_\alpha} m_{i,j} h_{i,j}, \quad (4.4)$$


kde

$$h_{i,j} = \begin{cases} 1 & \text{jestli } k\alpha \in [\beta_{i,j} - \gamma_{i,j}; \beta_{i,j} + \gamma_{i,j}], \\ 0 & \text{jinak.} \end{cases} \quad (4.5)$$

■ Binární polární histogram

Aby bylo možné určit kandidáty pro další směr pohybu, primární histogram musí být převeden do binární podoby.

$$H_{k,i}^b = \begin{cases} 1 & \text{jestli } H_{k,i}^p > \tau_{high}, \\ 0 & \text{jestli } H_{k,i}^p < \tau_{low}, \\ H_{k,i-1}^b & \text{jinak.} \end{cases} \quad (4.6)$$



Obrázek 4.2: Polární histogram s vyobrazenými prahy τ_{low} (zeleně) a τ_{high} (fialově)

■ Výběr kandidátů

Kandidáty pro nový směr pohybu se volí dle toho, do jaké kategorie je zařazeno volné místo v binárním histogramu. Ty průjezdy, které mají velikost (tedy vzdálenost mezi pravým okrajem k_r a levým k_l) menší, než s_{max} , se nazývají úzké, jiné jsou naopak nazývány široké.

Pro úzké průjezdy lze zvolit pouze jednoho kandidáta, a to:

$$c_n = \frac{k_r + k_l}{2} \quad \text{centrální sektor.} \quad (4.7)$$

Široké průjezdy mají tři možné kandidáty:

$$\begin{aligned} c_r &= k_r + \frac{s_{max}}{2} && \text{pravý sektor,} \\ c_l &= k_l - \frac{s_{max}}{2} && \text{levý sektor,} \\ c_t &= k_t && \text{pokud } k_t \in [c_r; c_l]. \end{aligned} \quad (4.8)$$

Nový směr pohybu se zvolí dle minimální ceny spočítané pro kandidáta c_i pomocí vztahu [18]

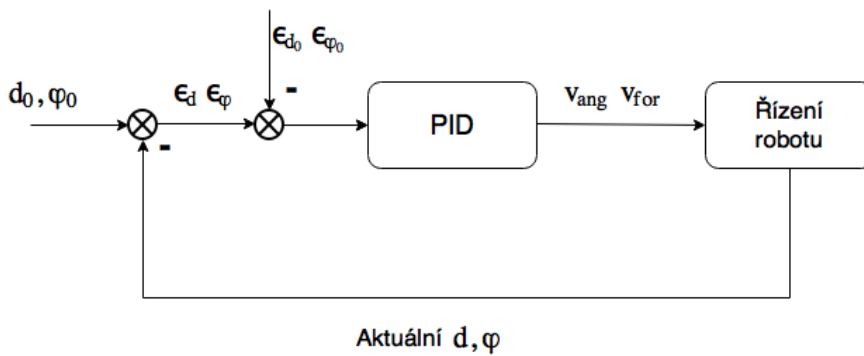
$$g(c_i) = \mu_1 \Delta(c_i, k_t) + \mu_2 \Delta\left(c_i, \frac{h}{\alpha}\right) + \mu_3 \Delta(c_i, k_{d,n-1}) \quad (4.9)$$

přičemž $k_{d,n-1}$ je minule zvolený kandidát, μ_1, μ_2, μ_3 jsou konstanty, zvolené dle vztahu $\mu_1 > \mu_2 + \mu_3$ a také platí, že

$$\Delta(c_1, c_2) = \min \left\{ |c_1 - c_2|, \left| c_1 - c_2 - \frac{360^\circ}{\alpha} \right|, \left| c_1 - c_2 + \frac{360^\circ}{\alpha} \right| \right\}. \quad (4.10)$$

4.2 PID regulátor

Za jízdy je třeba, aby byla mezi robotem a cílem udržována určitá vzdálenost d a hodnota úhlu ϕ byla co nejmenší, nejlépe nulová. Pro tyto účely je navržen diskretní PID regulátor [19], který pro aktuální odchylku od referenčních bodů spočte dopřednou a úhlovou rychlost, které se následně převedou na rychlosti motorů. Zjednodušený náčrt algoritmu je zobrazen na 4.3. Pokud je ϵ_d , resp. ϵ_ϕ , v pásmu $[-\epsilon_{d0}; \epsilon_{d0}]$, resp. $[-\epsilon_{\phi0}; \epsilon_{\phi0}]$, pak bude výstup PID regulátoru nulový. Jinak je od odchylky odečtena hodnota ϵ_{d0} , resp. $\epsilon_{\phi0}$, což zaručí to, že robot nebude kmitat na místě, pokud bude blízko referenčního bodu, a řízení bude plynulé.



Obrázek 4.3: PID regulace

Výsledná dopředná, resp. úhlová, rychlost v čase t je vypočtena pomocí vztahu

$$V_{for,ang} = K_p E + K_i I + K_d D, \quad (4.11)$$

kde K_p , K_i a K_d jsou koeficienty proporcionální, integrální a diferenciální složky PID regulátoru, a pro E , I , D platí, že

$$E = \begin{cases} \epsilon - \epsilon_0 & \text{jestli } |\epsilon| > \epsilon_0, \\ 0 & \text{jinak.} \end{cases} \quad (4.12)$$

$$I = \sum_t E_t \Delta t, \quad (4.13)$$

$$D = \frac{E_t - E_{t-1}}{\Delta t}. \quad (4.14)$$

Anti windup

Jelikož integrální složka pořád sčítá chybu, může dojít k tomu, že výstup PID regulátoru bude přesahovat maximální povolenou rychlost robotu, a tudíž ztrácí schopnost ji regulovat. Tomuto jevu se říká integrální windup. Aby

nedocházelo k nekontrolovanému výpočtu integrální složky, je v práci použita technika anti windup. Ta zajistí to, že integrál v čase $t + 1$ bude roven

$$I_{t+1} = \begin{cases} I_t + K_a E \Delta t & \text{jestli } |V| > V_{max}, \\ I_t + E \Delta t & \text{jinak,} \end{cases} \quad (4.15)$$

kde K_a je anti windup koeficient. V případě, že K_a bude roven 0, integrální složka se nezmění. Naopak pokud K_a je 1, anti windup bude ignorován.

Volba koeficientů

Při volbě koeficientů PID regulátoru je třeba mít na mysli vlastnosti každé složky (viz tabulka 4.2). Pro ladění těchto koeficientů lze použít např. Zieglerovu Nicholsovou metodu [20]. Princip metody spočívá v tom, že se nalezne kritické zesílení K_{pc} , při kterém systém, tedy robot, začne kmitat a zjistí se doba jedné oscilace P_c pro toto zesílení. Na základě těchto údajů se spočtou koeficienty složek použitého PID regulátoru (viz tabulka 4.3).

Koeficient	Doba náběhu	Overshoot	Doba ustálení	Chyba v ekvilibriu
K_p	Snižuje	Zvyšuje	Malá změna	Snižuje
K_i	Snižuje	Zvyšuje	Zvyšuje	Eliminuje
K_d	Malá změna	Snižuje	Snižuje	Žádná

Tabulka 4.2: Vliv zvětšení koeficientů PID regulátoru na kvalitu regulace

K ladění lze přistupovat i empiricky. Když je známa maximální rychlost, se kterou se robot může pohybovat, lze jednoduše odhadnout parametr K_p . Mělo by být zajištěno, že se robot bude pohybovat rychlostí, která je přímo úměrná chybě. Pokud je tedy očekávána maximální rychlost V_{max} a maximální odchylka od referenčního bodu je E_{max} , pak by mělo platit, že

$$K_p = \frac{V_{max}}{E_{max}}. \quad (4.16)$$

Ostatní parametry by se měly zvolit tak, aby nedocházelo ke zbytečnému kmitání robotu a rychlé odezvě na prudké změny polohy cíle.

Regulátor	K_p	K_i	K_d
P	$0.5K_{pc}$	0	0
PI	$0.45K_{pc}$	$1.2 \frac{K_{pc} \Delta t}{P_c}$	0
PD	$0.8K_{pc}$	0	$K_{pc} \frac{P_c}{8\Delta t}$
PID	$0.6K_{pc}$	$2 \frac{K_{pc} \Delta t}{P_c}$	$K_{pc} \frac{P_c}{8\Delta t}$

Tabulka 4.3: Nastavení koeficientů PID regulátoru pomocí Zieglerovy Nicholsovy metody

Kapitola 5

Simulace

Pro simulaci byl zvolen simulátor V-Rep [21]. V tomto prostředí byly vytvořeny dva roboty: jeden s vizuální značkou, druhý vybaven kamerou a laserovým dálkoměrem sledoval prvního (viz obr. 5.1). Robot s vizuální značkou je řízen uživatelem pomocí klávesnice. Referenční vzdálenost mezi dvěma roboty byla zvolena 1 m, požadovaná odchylka vizuální značky od středu kamery 0 rad. Maximální dopřední rychlost obou robotů byla nastavena na 2.5 m s^{-1}


5.1 Porovnání algoritmů detekce

Oba algoritmy byly porovnávány při použití značky o velikosti $10 \times 10 \text{ cm}$ a rozlišením kamery $512 \times 512 \text{ pixelů}$. Bylo porovnáno několik parametrů, a to maximální vzdálenost, na které je vizuální značka ještě detekovatelná, stabilní vzdálenost, při které je značka detekována bez přerušení. Dále byl porovnán maximální a stabilní úhel otočení vizuální značky vůči robotu a také průměrný výpočetní čas na jednu iteraci algoritmu. Výsledky jsou znázorněny v tabulce 5.1. Je patrné, že detekční schopnosti korelačního algoritmu jsou poněkud horší, než u ArUco detektoru. Avšak je třeba zdůraznit, že ArUco detektor sice dokázal rozpoznat vizuální značku na vzdálenosti přes 5 metrů od kamery, úspěšnost detekcí na tak velké vzdálenosti byla podprůměrná, přibližně 40 %. Co se týká úhlu otočení značky vůči robotu, tam se korelační algoritmus ukázal být lepší a stabilně detekuje značku při 60° otočení. ArUco má na hranicích detekovatelnosti, tj. při 70° otočení, pouze 15% úspěšnost.

Název algoritmu	Korelační algoritmus	ArUco detektor
Max. vzdálenost [m]	3.5	5.4
Stabilní vzdálenost [m]	3.5	3.8
Max. úhel $[\circ]$	60	70
Stabilní úhel $[\circ]$	60	55
Výpočetní doba [ms]	15	15

Tabulka 5.1: Porovnání korelačního algoritmu a ArUco detektoru

Hlavní rozdíl mezi těmito algoritmy spočívá v možnostech jejich využití. Zatímco ArUco detektor je zaměřený pouze na ArUco markery, korelační



Obrázek 5.1: Roboty vytvořené v simulátoru V-Rep


algoritmus je obecnější a dá se použít na jakýkoliv typ vizuální značky. ArUco detektor umožňuje přidání dalších značek do své knihovny, ale jedná se pouze o binární obrázky podobné znázorněnému na obr. 3.2.2. Korelační algoritmus by měl detekovat i značku, kterou nelze reprezentovat jako bit-mapu, viz např. obr. 5.2.



Obrázek 5.2: Příklad značky pro korelační algoritmus


■ 5.2 Porovnání naměřených a reálných hodnot

Jelikož se v implementovaném programu provádí různé výpočty, je třeba porovnat, jakou mají tyto hodnoty odchylku vůči reálným. Kalmanův filtr, popsáný v 3.4, predikuje polohu cíle a v případě neúspěšné detekce vizuální značky je umístění sledovaného objektu vůči robotu odvozeno právě z predi-




Obrázek 5.3: Poloha sledovaného objektu během simulace

kované polohy. Na obrázku 5.3 lze vidět, že výpočet pomocí Kalmanova filtru skoro po celou dobu simulace odpovídá reálné poloze sledovaného objektu. Velká odchylka pak je až na konci simulace, kdy vizuální značka brzo zmizela ze zorného pole robotu a nebylo možné ji v krátké době najít. Toto také odpovídá výsledkům, které jsou na 5.4 a 5.5, kde je vidět, že po cca 2000. iteraci je rozdíl mezi změřenými a reálnými hodnotami výrazný.



Obrázek 5.4: Vzdálenost mezi robotem a sledovaným objektem (d)

Na obrázku 5.4 je také vidět, že změřená vzdálenost není stejná, jako reálná. Je to způsobeno nepřesnou kalibrací referenční vzdálenosti mezi



Obrázek 5.5: Odchylka sledovaného objektu od středu kamery ϕ

následovaným a sledujícím robotem. Kdyby kalibrace byla přesnější, bylo by možné dosáhnout podobného výsledku, jako pro odchylku od středu kamery (viz obr. 5.5), kde měření odpovídá reálné hodnotě.


5.3 Měření polohy robotu

Jak bylo řečeno v 3.4, aby bylo možné spočítat polohu cíle vůči robotu, je třeba znát polohu robotu v globálních souřadnicích. Ačkoliv simulátor V-Rep nabízí možnosti pro přesné měření polohy objektů ve světových souřadnicích, v reálném světě tato možnost nemusí být použitelná, protože např. při navigaci robotu uvnitř budov nelze použít GPS. Proto byl v sekci 2.2 zaveden relativní souřadnicový systém, ve kterém se poloha robotu počítá. Pro toto měření lze v simulátoru odečítat vnitřní polohu rotačních kloubů robotu, na které jsou přiděleny kola. V případě robotu s diferenciálním řízením, jeho pozici lze spočítat jako:

$$\begin{bmatrix} x \\ y \\ h \end{bmatrix} = \begin{bmatrix} x + \frac{(\Delta R + \Delta L)r_k}{2} \cos(h) \\ y + \frac{(\Delta R + \Delta L)r_k}{2} \sin(h) \\ h + \frac{(\Delta R - \Delta L)r_k}{2r_r} \end{bmatrix}, \quad (5.1)$$

přičemž ΔL a ΔR značí změnu vnitřní polohy levého a pravého kloubů za čas Δt , r_k je poloměr kola a r_r je poloměr robotu, neboli polovina vzdálenosti mezi koly.


Porovnání reálné, tj. v simulátoru změřené, a vypočtené polohy robotu ve zvoleném souřadnicovém systému lze vidět na obrázku 5.6. Je patrné, že pro použitý typ robotu a relativní souřadnicovou soustavu je výpočet přesný a při použití přesných enkodérů lze tento výpočet aplikovat i na reálném robotu.



Obrázek 5.6: Poloha robotu během simulace

5.4 Trajektorie robotu při jízdě s překážkami

Po ověření funkčnosti detektorů a řízení robotu byl v simulátoru vytvořen model prostředí, ve kterém by robot měl sledovat člověka se značkou. Do scény byli umístěni i jiní lidé, a také různé překážky: kytky, stůl, strom, křeslo, sloup, jak je vidět na 5.7.




Obrázek 5.7: Simulace s člověkem a překážkami

Člověk měl předem definovanou cestu, kterou přesně dodržoval nehledě na překážky, proto procházel skrz ostatní objekty bez jakýchkoliv následků.

Robot se ostatním objektům měl vyhýbat.

Trajektorie člověka a robotu jsou na obrázku 5.8. Šedě je na obrázku znázorněna kytka, zeleně strom a růžově kolemjdoucí, který během simulace přišel na uvedenou pozici. Jak je vidět, robot se snažil dodržovat trajektorii, podle které šel sledovaný člověk a přitom dokázal objíždět překážky, které mu v tom bránily. Nejproblematictější část simulace byla na začátku, kdy člověk strmě zahnul doprava. V ten okamžik byla vizuální značka špatně detekovatelná, protože byla otočena vůči robotu téměř o 90° . Navíc v určitém časovém intervalu byla značka skryta za listím, takže ji použitý algoritmus nedokázal najít ve snímku. Avšak tady je vidět, jak přínosné je použití Kalmanova filtru, který dokázal předpovědět na základě mála měření, kde se člověk nachází, proto ho robot rychle našel a sledoval i nadále.



Obrázek 5.8: Trajektorie robotu a člověka

Dalším problematickým úsekem byla cesta mezi stromem a kolemjdoucím. Jelikož sledovaný člověk mohl procházet skrz objekty, došlo k tomu, že, když mu v cestě stal kolemjdoucí, prošel skrz něj a pokračoval dále. Značka tedy opět nebyla detekovatelná. Navíc mezi stromem a kolemjdoucím byl velice úzký průjezd a robot musel snížit rychlost, aby tam dokázal projet. Nakonec však robot našel sledovaného člověka a jel za ním až do konce simulace.

Kapitola 6

Závěr

Cílem této práce bylo navrhnout software pro autonomní řízení robotu následujícího člověka.

Pro detekci člověka v obrazu bylo rozhodnuto použít vizuální značku, která byla robotem známa, funkčnost takového řešení byla ověřena simulací. Robot dokáže spočítat vzdálenost a směr, ve kterém se detekovaná značka vůči němu nachází. Díky dálkoměru robot také ví, jestli na cestě k cíli jsou překážky. Pokud ano, pomocí Vector Field Histogram algoritmu je vypočten nový směr jízdy tak, aby robot nenarazil na žádnou překážku a zároveň byl co nejblíže člověku. Na základě spočtených parametrů se pomocí PID regulátoru vyhodnotí rychlosti, které je třeba aplikovat na motory, aby robot dosáhl cílové pozice vůči sledovanému člověku. Navíc pro případ, kdy robot nedetekuje značku, a tedy ani nedokáže spočítat vzdálenost k cíli, je použit Kalmanův filtr, který předpovídá polohu cíle na základě předchozích měření.

V simulátoru bylo provedeno několik testů s roboty, nastavení simulací a výsledky některých testů jsou popsány v kapitole 5. Průměrná vzdálenost d mezi roboty byla 0.95 m a odchylka sledovaného robotu od středu kamery ϕ stanovila 0.0023 rad. Dále byl spočítán rozdíl mezi reálnou a vypočtenou pomocí Kalmanova filtru polohou sledovaného robotu, ten stanovil 0.32 m. Tak velká odchylka byla způsobena tím, že byly simulovány situace, kdy značka zmizí ze zorného pole robotu. Avšak robot dokázal pokaždé najít značku znovu a pokračovat v jízdě.

Tato práce byla velkým přínosem hlavně proto, že v ní byla možnost vyzkoušet různé techniky používané pro řízení mobilních robotů. Navíc díky této práci jsme se seznámili s simulačními prostředí pro robotiku a OpenCV knihovnou, která je běžně používána pro implementaci softwaru pro počítačové vidění a strojové učení.

Příloha A

Literatura

- [1] Derek Bradley and Gerhard Roth. Adaptive thresholding using the integral image. *Journal of Graphics Tools*, 12(2):13–21, 2007.
- [2] Opencv: Contours hierarchy. http://docs.opencv.org/trunk/d9/d8b/tutorial_py_contours_hierarchy.html.
- [3] Roland Siegwart, Illah Reza Nourbakhsh, and Davide Scaramuzza. *Introduction to autonomous mobile robots*. MIT Press. 272–290, 2004.
- [4] J Blanco, W Burgard, R Sanz, and JL Fernandez. Fast face detection for mobile robots by integrating laser range data with vision. In *Proc. of the International Conference on Advanced Robotics (ICAR)*, volume 2, pages 953–958. Citeseer, 2003.
- [5] Muhammad Sarmad Hassan, Mafaz Wali Khan, and Ali Fahim Khan. Design and development of human following robot. *Student Research Paper Conference*, 2, Jul 2015.
- [6] Andrej Babinec, Ladislav Jurišica, Peter Hubinský, and František Duchoň. Visual localization of mobile robot using artificial markers. *Procedia Engineering*, 96:1–9, 2014.
- [7] Xu Liu, David Doermann, Huiping Li, K. C. Lee, Hasan Ozdemir, and Lipin Liu. A novel 2d marker design and application for object tracking and event detection. *Lecture Notes in Computer Science*, 5358.
- [8] S. Garrido-Jurado, R. Muñoz-Salinas, F.j. Madrid-Cuevas, and M.j. Marín-Jiménez. Automatic generation and detection of highly reliable fiducial markers under occlusion. *Pattern Recognition*, 47(6):2280–2292, 2014.
- [9] Opencv: About. <http://opencv.org/about.html>.
- [10] F. Jurie and M. Dhome. A simple and efficient template matching algorithm. *Proceedings Eighth IEEE International Conference on Computer Vision. ICCV 2001*.
- [11] Template matching. http://docs.adaptive-vision.com/4.7/studio/machine_vision_guide/TemplateMatching.html.

- [12] OpenCV: Detection of aruco markers. http://docs.opencv.org/3.1.0/d5/dae/tutorial_aruco_detection.html.
- [13] Urs Ramer. An iterative procedure for the polygonal approximation of plane curves. *Computer Graphics and Image Processing*, 1(3):244 – 256, 1972.
- [14] Paul Prober and Bill Wellman. Optimum pinhole camera design. *Hue Candela*, 2002.
- [15] Erik Cuevas, Daniel Zaldivar, and Raul Rojas. Kalman filter for vision tracking. Aug 2005.
- [16] Rogger Labbe. *Kalman and Bayesian Filters in Python*.
- [17] J. Borenstein and Y. Koren. The vector field histogram-fast obstacle avoidance for mobile robots. *IEEE Transactions on Robotics and Automation*, 7(3):278–288, 1991.
- [18] R.J. van Breda and W.J. Smit. Applicability of vector field histogram star (vfh*) on multicopters. *International Micro Air Vehicles, Conferences and Competitions*, 2016.
- [19] Rich LeGrand. Closed-loop motion control for mobile robotics. *Circuit Cellar*, (169):34–46, Aug 2004.
- [20] N. B. Nichols J. G. Ziegler. Optimum settings for automatic controller. *Trans. ASME*, 64, 1942.
- [21] Coppelia robotics v-rep. <http://www.coppeliarobotics.com/index.html>.

Příloha B

Obsah CD

```
system
├── config
├── lib
│   ├── Access
│   └── Plugin
├── templates
└── tests
```